Projet « Enquête sur une maladie »

Date limite de remise : vendredi 20 novembre 2026 à 23h59. Aucun retard accepté.

Votre groupe choisit un jeu de données réel en santé ou en génomique, pose une question précise sur une maladie, définit un **motif** (un pattern : une séquence, un variant, une combinaison de critères, un profil d'expression) et construit un **pipeline reproductible** qui le recherche automatiquement.

Le sujet est libre. Ce qui est imposé, c'est le cadre technique : il couvre les cinq chapitres du module (shell, manipulation de fichiers, administration système, programmation de script, Python).

Quelques pistes (vous pouvez en proposer d'autres) :

- gènes de résistance aux antibiotiques : génomes bactériens du NCBI, motif présent chez les souches résistantes et absent chez les autres ;
- variants et maladie génétique : ClinVar et 1000 Genomes sur un gène ou un panel, variants pathogènes fréquents ;
- expression dans un cancer : jeu GEO tumeur contre tissu sain, gènes qui distinguent les deux groupes ;
- facteurs de risque : jeux UCI ou Kaggle (diabète, maladie cardiaque), combinaison de critères qui prédit la maladie ;
- évolution d'un virus : NCBI Virus, mutations apparues selon la date ou la région.

Contraintes sur les données : publiques et librement téléchargeables ; entre 100 Mo et 1 Go ; pas de données personnelles non anonymisées ni de jeu à accès contrôlé. **Un sujet et un jeu de données par groupe** : en cas de doublon, le premier groupe qui a remis sa fiche est prioritaire.

3. Fiche de validation du sujet

À remettre sur Google Classroom avant le vendredi 23 octobre 2026 à 23h59. Une page, ces rubriques :

Rubrique	Contenu attendu
Groupe et membres	Numéro de groupe, noms des 5 étudiants
Jeu de données	Nom, identifiant (ou lien), taille, date de téléchargement
Maladie et question	La question posée, en une ou deux phrases

Vous recevez une réponse « validé » ou « à ajuster » sous 3 jours. Ne commencez pas le développement avant validation.

4. Cadre technique imposé

Votre dépôt contient un script unique **`run.sh`** qui exécute tout le pipeline, de la donnée brute jusqu'aux résultats.

- **Shell :** acquisition, filtrage et nettoyage des données avec les outils standard (`grep`, `sed`, `awk`, `cut`, `sort`, `uniq`...), en enchaînant des commandes par tubes.
- **Manipulation de fichiers :** arborescence claire (`data/`, `scripts/`, `results/`, `logs/`), sommes de contrôle, archivage des résultats.
- **Administration système :** environnement logiciel isolé et reproductible, tâche planifiée, journaux horodatés, droits d'accès corrects.
- **Programmation de script :** arguments (`getopts`), aide `-h`, gestion des erreurs et des signaux (`trap`), codes de retour.
- **Python :** analyse statistique du résultat et figures, appelées depuis `run.sh`.

Votre pipeline doit y fonctionner sans intervention manuelle, en suivant uniquement votre `README.md`.

5. À remettre sur Google Classroom

Une archive `Projet_Maladie_Groupe_XX.zip` contenant :

- `LIEN_GIT.txt` : adresse du dépôt d'équipe **et hash du commit final** (seul ce commit est évalué) ;
- le code du pipeline (`run.sh` et les scripts) ;
- `README.md` : installation, mode d'emploi, répartition du travail, description des fichiers produits ;
- `SOURCES.md` : identifiant, adresse et date de téléchargement du jeu de données ;
- `rapport.pdf` : 4 pages maximum (question, données, méthode et définition du motif, résultats, limites).

Les données elles-mêmes ne sont pas à joindre : votre script doit les télécharger et vérifier leur intégrité.

Une version fonctionnelle est à déposer le lundi 9 novembre 2026 à 23h59 pour le test croisé du point 7.

L'absence de l'archive ou une remise hors délai entraîne la note de 0.

6. Grille de critères techniques

Chaque critère se vérifie par oui ou non, sans jugement subjectif. Il y en a 20, à 1 point chacun.

Chapitre	Critères
Shell	`run.sh` affiche une aide avec `-h` · au moins deux options traitées avec `getopts` · un fichier manquant provoque un code de retour non nul et un message clair · au moins un enchaînement de 3 commandes ou plus par tubes sur les données
Fichiers	arborescence décrite dans le README · sommes de contrôle calculées et vérifiées par le script · résultats archivés dans une archive datée (`tar`) · `SOURCES.md` complet
Administration système	environnement reproductible fourni (`environment.yml` ou `requirements.txt`) · tâche `cron` ou timer fournie et documentée · journal horodaté dans `logs/` · scripts exécutables et données brutes en lecture seule
Script	`trap` qui supprime les fichiers temporaires à l'interruption · arrêt à la première erreur (`set -euo pipefail`) avec message clair · au moins 3 fonctions réutilisées · relance possible sans nettoyage manuel
Python	script appelé par `run.sh` avec `argparse` · au moins une figure produite automatiquement · résultats chiffrés écrits dans un fichier CSV ou JSON · au moins un test automatique du traitement

7. Test croisé entre groupes

Du 9 au 13 novembre, chaque groupe reçoit la version fonctionnelle d'un autre groupe et tente de la lancer **en suivant uniquement son README**. Il remet sous 48 heures un compte rendu court (fichier modèle fourni) : le pipeline démarre-t-il, va-t-il au bout, produit-il les fichiers annoncés, qu'est-ce qui manque dans le README. Les remarques servent à corriger avant la remise finale.

8. Évaluation

Élément	Part
Exécution du pipeline sur une machine propre (il démarre, va au bout, produit les fichiers annoncés dans le README)	20 %
Grille de critères techniques (point 6)	25 %
Rapport de 4 pages	20 %
Test croisé : compte rendu remis et pertinent	5 %
Soutenance orale individuelle	30 %

9. Soutenance orale

- 25 minutes par groupe, dont 10 minutes de présentation allant à l'essentiel.
- Le reste du temps : **questions individuelles précises** sur les concepts utilisés et **petite modification de votre code en direct**, demandée à l'étudiant désigné.
- Les notes d'un même groupe ne sont pas forcément identiques.

Les dates des soutenances seront communiquées après la remise.

10. Calendrier

Date	Étape
Vendredi 23 octobre	Fiche de validation du sujet
Du 26 octobre au 6 novembre	Développement, point de 5 minutes avec l'enseignant par groupe
Lundi 9 novembre	Version fonctionnelle déposée
Du 9 au 13 novembre	Test croisé
Vendredi 20 novembre, 23h59	Remise finale

11. Règles

Vous êtes responsables de chaque ligne que vous rendez : vous devez pouvoir l'expliquer et la modifier à l'oral, quelle que soit la manière dont elle a été produite. Les projets très similaires entre groupes seront examinés. En cas de contestation de la note, un étudiant dispose de 48 heures après sa publication pour écrire à l'enseignant en expliquant son cas.