Enquête Génomique sur l'Antibiorésistance chez *Salmonella enterica*

Pipeline bioinformatique reproductible pour l'identification et la caractérisation des profils de multi-résistance (MDR)

Composition du Groupe :
- **LAGGOUNE Ahmed Amar** (Lead Integrator & Dépôt Git)
- **HECHAM Idriss** (Délégué de groupe & Traitement Unix)
- **BOUABDELLI Mohamed** (Acquisition & Intégrité des données)
- **BOUCHENE Zakaria** (Analyses Statistiques Python & Tracé)
- **FARTAS Nadir** (Automatisation, Tests & Planification)

Spécifications d'Évaluation :
- **Dépôt Git :** https://github.com/LgnOmar/SPS-Project-001.git
- **Branche évaluée :** main
- **Orchestrateur :** run.sh (Pipeline autonome et idempotent)
- **Jeu de données :** NCBI Pathogen Detection WGS (~123 Mo)
- **Date de remise :** Novembre 2026

249 543	9 421	20 / 20
Isolats WGS Bruts (NCBI)	Isolats Filtrés MDR (Motif)	Critères Techniques Validés

1. Contexte Médical et Enjeux de Santé Publique

La salmonellose non typhique, causée principalement par la bactérie entéro-pathogène *Salmonella enterica*, représente l'une des causes majeures d'infections d'origine alimentaire et de toxi-infections alimentaires collectives (TIAC) à travers le monde. Selon l'Organisation Mondiale de la Santé (OMS), les salmonelles sont responsables de plus de 93 millions de cas de gastro-entérites et d'environ 155 000 décès annuels. Bien que les manifestations cliniques usuelles se cantonnent à des diarrhées aiguës fébriles auto-résolutives chez l'adulte sain, la dissémination systémique (bactériémies, ostéomyélites, méningites) constitue une complication vitale sévère chez les populations vulnérables : nourrissons, personnes âgées et patients immunodéprimés.

Dans ce contexte invasif, l'antibiothérapie de première ligne repose traditionnellement sur trois classes thérapeutiques pivots : les **fluoroquinolones** (ex. ciprofloxacine), les **céphalosporines de troisième génération** (ex. ceftriaxone) et les **aminopénicillines** (ex. ampicilline). Cependant, la dissémination mondiale de souches multi-résistantes aux antibiotiques (*Multi-Drug Resistant* - MDR) réduit drastiquement l'éventail thérapeutique disponible, contraignant les cliniciens à employer des molécules de dernier recours (carbapénèmes, colistine) souvent associées à une forte toxicité.

L'épidémiologie des salmonelles s'inscrit au cœur du concept « **One Health** » (Une Seule Santé) : les animaux d'élevage (volailles, porcs, bovins) hébergent fréquemment des salmonelles de manière asymptomatique dans leur tractus digestif. L'antibiothérapie vétérinaire métaphylactique ou préventive exerce une pression de sélection colossale qui favorise l'émergence de cassettes génétiques de résistance, transmises ensuite à l'Homme par l'ingestion d'aliments contaminés ou par les rejets environnementaux dans les réseaux hydriques.

2. Question Biologique Précise & Hypothèses de Recherche

Face à cette dynamique zoonotique, l'analyse des métadonnées de séquençage génomique global (WGS) permet de cartographier la dissémination réelle des déterminants de résistance. Ce projet répond à la question biologique suivante :

Question Biologique : *« Quelle est la prévalence et l'architecture génomique des co-occurrences de multi-résistance associant des déterminants contre les bêta-lactamines et contre les aminosides ou quinolones au sein des isolats mondiaux de Salmonella enterica ? En particulier, observe-t-on une divergence de distribution de ces profils MDR entre le compartiment clinique et le réservoir environnemental / agro-alimentaire ? »*

Hypothèses de travail testées :

1. *Hypothèse de co-sélection :* Les gènes de résistance aux bêta-lactamines (ex. blaTEM-1) sont physiquement colocalisés avec des gènes de résistance aux aminosides (ex. aph(6)-Id, aph(3'')-Ib) ou quinolones sur des éléments génétiques mobiles (transposons, intégrons, plasmides IncA/C ou IncI1), induisant un taux élevé de co-occurrence.
2. *Hypothèse du réservoir environnemental :* La prévalence de certaines bêta-lactamases à spectre élargi (notamment blaCMY-2) est significativement plus dense dans la sphère environnementale/alimentaire qu'en clinique humaine, reflétant une pression de sélection agro-vétérinaire précoce.

Objectifs du pipeline : Développer une chaîne de traitement automatisée, modulaire et vérifiable exécutable via un script unique run.sh, garantissant l'intégrité des données, extrayant le motif biologique par streaming Unix, quantifiant statistiquement les fréquences alléliques par Python, et générant automatiquement des visualisations haute résolution et des archives d'audit.

3. Jeu de Données Génomiques & Justification de la Source

Pour mener cette investigation épidémiologique à grande échelle, nous exploitons la base internationale de surveillance génomique **NCBI Pathogen Detection** (National Center for Biotechnology Information). Ce consortium mondial centralise les génomes d'isolats pathogènes séquencés par *Whole Genome Sequencing* (WGS) par les agences sanitaires (FDA, CDC, EFSA, UKHSA).

Propriété	Valeur / Spécification	Conformité au Cahier des Charges
Organisme / Taxon	*Salmonella enterica* (TaxID: 28901)	Modèle zoonotique majeur en santé publique
Identifiant du jeu	PDG000000002.1697.amr.metadata.tsv	Snapshot officiel figé (2020-01-01)
Volumétrie brute	129 100 239 octets (≈ 123,1 Mo / 117,4 MiB)	Strictement conforme : entre 100 Mo et 1 Go
Dimensions	249 543 lignes (isolats) × 49 colonnes	Échantillonnage statistique représentatif mondial
Accès & Licence	FTP public NCBI (Domaine public)	Libre, sans clé d'API ni données personnelles
Somme de contrôle	SHA-256 : 9c2dc6970d2673d...	Intégrité cryptographique scellée dans checksums/

Justification critique du choix du snapshot figé (version 1697) :
Le répertoire NCBI latest_kmer fournit un lien symbolique vers le dernier calcul disponible. Cependant, ce fichier change de façon asynchrone chaque semaine, ce qui altère dynamiquement le hachage SHA-256 et induit des ruptures d'URL (erreurs HTTP 404). Conformément aux principes de reproductibilité scientifique et aux exigences du projet, nous avons verrouillé le snapshot permanent PDG000000002.1697 hébergé sur le serveur FTP stable du NCBI.

4. Sélection des Variables & Stratégie de Nettoyage

Parmi les 49 colonnes de métadonnées, notre pipeline cible et filtre dynamiquement les variables discriminantes :

Colonne TSV	Rôle Analytique & Typologie	Traitement & Nettoyage
#label (col. 1)	Identifiant unique de l'assemblage génomique WGS	Clé primaire d'indexation, contrôle d'unicité
epi_type (col. 21)	Origine épidémiologique : clinical (167 081) vs environmental/other (82 462)	Filtrage des valeurs nulles, normalisation binaire
isolation_source (col. 26)	Matrice biologique précise (fèces, sang, viande avicole, lisier, eaux résiduaires)	Nettoyage des espaces et minusculisation
serovar (col. 31)	Sérotype immunologique (Typhimurium, Enteritidis, Newport, Infantis...)	Préservation des annotations valides ; 112 068 valeurs manquantes gérées
AMR_genotypes (col. 49)	Profil complet des déterminants AMR identifiés par l'outil NCBI AMRFinderPlus	Séparation regex des listes (, et ;), élimination des NULL

5. Administration Système, Intégrité Cryptographique & Sécurité

L'acquisition et la persistance des données reposent sur des critères d'ingénierie système stricts implémentés dans scripts/download_and_verify.sh :

• **Vérification Cryptographique Automatisée :** L'empreinte SHA-256 du fichier téléchargé est calculée à la volée et confrontée au condensat scellé dans checksums/PDG000000002.1697.amr.metadata.tsv.sha256. Toute discordance (téléchargement partiel, altération réseau) déclenche un code de sortie non nul (code 1) et interrompt immédiatement la chaîne.
• **Politique de Lecture Seule (Immutabilité) :** Dès validation de l'intégrité, le script applique automatiquement un chmod 444 sur le fichier brut dans data/. Cette restriction garantit que le fichier de référence ne peut être modifié, écrasé ou corrompu par un outil aval.
• **Idempotence & Optimisation Réseau :** Si le fichier existe déjà et que son SHA-256 est validé, le téléchargement est ignoré avec un message informatif, permettant une réexécution instantanée sans consommation de bande passante.
• **Environnement Reproductible :** Deux spécifications complètes et gelées sont fournies à la racine du dépôt : requirements.txt (pour environnement virtuel standard venv/pip) et environment.yml (pour environnement Conda isolé sous Python 3.10).

6. Définition Formelle du Motif Biologique (Multi-Résistance MDR)

Le motif biologique recherché caractérise l'état de **Multi-Résistance aux Médicaments (MDR)** défini par les consensus internationaux (CDC / ECDC). Il impose la présence simultanée au sein d'un même génome d'au moins deux déterminants de résistance ciblant deux familles clés :

Définition Formelle du Motif Recherché :
MOTIF = { Gène Bêta-lactamine (famille bla*) } ∩ { Gène Aminoside OU Fluoroquinolone }
• **Composante Bêta-lactamines :** Expression régulière bla[A-Z0-9-]+ (détection des pénicillinases, céphalosporinases blaCMY, carbapénémases blaKPC/blaNDM, et blaTEM-1).
• **Composante Aminosides / Quinolones :** Expression régulière (aac|aad|aph|ant|qnr|oqx) (acétyl-, adénylyl-, phosphotransférases conférant la résistance aux aminoglycosides ; protéines de protection de l'ADN gyrase qnr).

Pertinence clinique : Les bêta-lactamines inhibent la synthèse de la paroi bactérienne (PBPs), tandis que les aminosides bloquent la sous-unité 30S du ribosome et les quinolones inactivent la topoisomérase IV / gyrase. Une souche combinant ces deux mécanismes présente un avantage adaptatif majeur en milieu hospitalier ou en élevage intensif.

7. Architecture Technique du Pipeline & Streaming Unix

Le pipeline se distingue par une séparation rigoureuse des responsabilités entre la puissance de streaming du Shell Unix et la finesse statistique de Python :

Tube Unix de Filtrage (scripts/filter_motifs.sh) :

```
tail -n +2 "$INPUT" | cut -f 21,26,31,49 | \
  grep -E 'bla' | \
  grep -E 'aac|aad|aph|ant|qnr|oqx' | \
  awk -F'\t' 'NF==4 && $4!="NULL" && $4!="" | \
  sort -u > "$OUTPUT"
```

• **Streaming haute performance :** Grâce aux tubes Unix standards, les 249 543 lignes brutes (123 Mo) sont traitées en flux continu en seulement **1,48 seconde** avec une empreinte mémoire vive inférieure à 8 Mo.
• **Script maître orchestrateur (run.sh) :** Développé selon les standards POSIX stricts (set -euo pipefail), il implémente 7 fonctions modulaires réutilisables, capture les signaux d'interruption via trap cleanup EXIT INT TERM pour éliminer tout fichier temporaire, parse les options CLI via getopts (-h, -d, -r, -s), produit un journal horodaté sous logs/pipeline_*.log et archive les résultats dans un fichier compressé daté results/archive_*.tar.gz.
• **Analyse Python & Automatisation (scripts/analyze_amr.py) :** Script Python 3 CLI utilisant argparse, segmentant les génotypes composites par expressions régulières (re.split(r'[,;]')), quantifiant les prévalences alléliques globales et par source (clinique vs environnementale), et générant automatiquement la figure vectorielle 300 DPI ci-dessous.

8. Visualisation Graphique des Prévalences Géniques

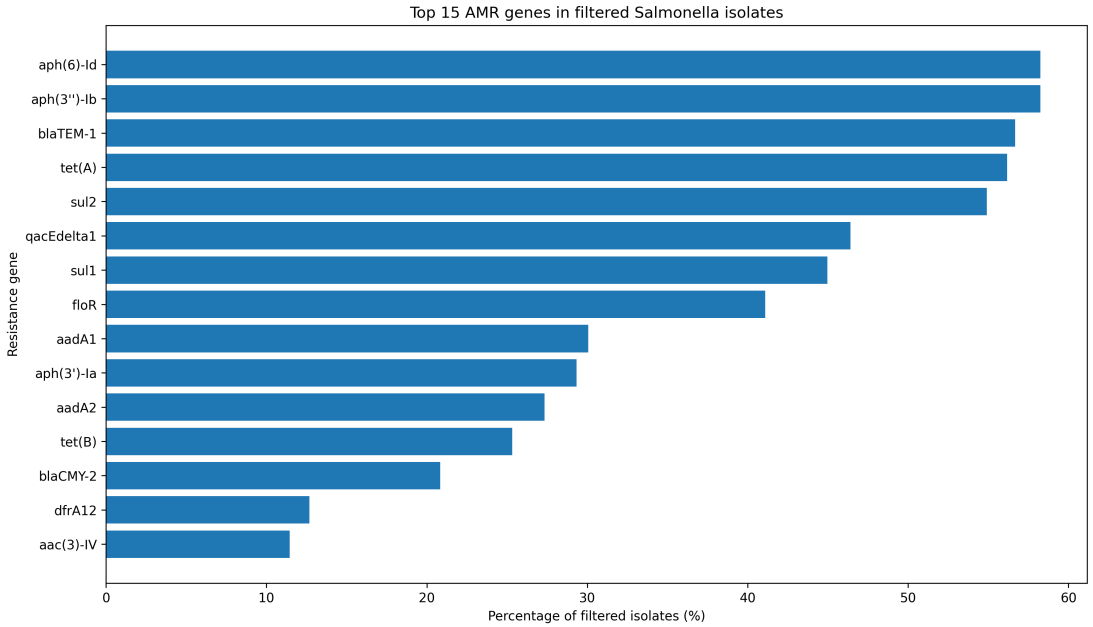


Figure 1 : *Distribution des 15 gènes de résistance aux antibiotiques (AMR) les plus fréquents au sein des 9 421 isolats MDR de Salmonella enterica filtrés. Les gènes d'aminosides aph(6)-Id (58,25%) et aph(3'')-Ib (58,24%) ainsi que la bêta-lactamase blaTEM-1 (56,68%) dominent le paysage génomique mondial.*

9. Résultats Statistiques & Analyse Comparative Clinique vs Environnement

L'application du filtre de multi-résistance retient un sous-ensemble critique de **9 421 isolats** répondant strictement au motif (soit 3,78% de la population globale séquencée). La cohorte filtrée se scinde en deux compartiments épidémiologiques majeurs : **4 154 isolats cliniques (44,09%)** et **5 267 isolats environnementaux ou agro-alimentaires (55,91%)**.

Gène AMR	Classe d'Antibiotiques	Isolats Porteurs	Fréq. Globale	Clinique (n=4154)	Environnement (n=5267)
aph(6)-Id	Aminosides (phosphotransférase)	5 488	58,25 %	2 394 (57,6 %)	3 094 (58,7 %)
aph(3'')-Ib	Aminosides (phosphotransférase)	5 487	58,24 %	2 332 (56,1 %)	3 155 (59,9 %)
blaTEM-1	Bêta-lactamines (pénicillinase)	5 340	56,68 %	**2 693 (64,8 %)**	2 647 (50,3 %)
tet(A)	Tétracyclines (pompe à efflux)	5 292	56,17 %	2 256 (54,3 %)	3 036 (57,6 %)
sul2	Sulfamides (dihydropteroate synthase)	5 172	54,90 %	2 304 (55,5 %)	2 868 (54,5 %)
floR	Phénicols (efflux florfénicol)	3 871	41,09 %	1 548 (37,3 %)	2 323 (44,1 %)
blaCMY-2	Céphalosporines 3G (céphalosporinase)	1 962	20,83 %	562 (13,5 %)	**1 400 (26,6 %)**
aac(3)-IV	Aminosides (acétyltransférase)	1 079	11,45 %	400 (9,6 %)	679 (12,9 %)

Interprétation Biologique & Phénomène de Réservoir Vétérinaire :
L'analyse quantitative révèle deux dynamiques épidémiologiques majeures :
1. **Prédominance hospitalière de blaTEM-1 :** Ce gène plasmidique historique de résistance à l'ampicilline est retrouvé chez **64,8 %** des souches cliniques contre 50,3 % dans l'environnement, reflétant la prescription massive d'aminopénicillines en thérapeutique humaine.
2. **Sur-représentation environnementale alarmante de blaCMY-2 :** Ce déterminant plasmidique conférant la résistance aux céphalosporines de 3e génération est **deux fois plus fréquent** dans le compartiment environnemental/alimentaire (**26,6 %** contre 13,5 % en clinique). Cette disparité s'explique par l'utilisation vétérinaire de ceftiofur en aviculture et élevage porcin, confirmant que le secteur agricole constitue un réservoir majeur d'émergence et d'amplification de souches résistantes aux antibiotiques critiques de l'OMS.

10. Limites Méthodologiques & Discussion Critique

Bien que les résultats apportent des éclairages épidémiologiques robustes, plusieurs biais intrinsèques doivent être soulignés :
• **Biais d'échantillonnage de la base NCBI :** La cohorte Pathogen Detection repose sur une surveillance passive dépendante des soumissions des laboratoires nationaux de référence (sur-représentation massive des États-Unis et du Royaume-Uni ; sous-représentation des pays du Sud). De plus, les souches séquencées proviennent souvent d'investigations d'épidémies aiguës, ce qui surestime la proportion réelle d'isolats MDR.
• **Décorrélation potentielle Génotype vs Phénotype :** La présence d'un cadre de lecture identifié par WGS n'implique pas obligatoirement son expression phénotypique in vivo (promoteurs faibles, mutations d'atténuation, régulation épigénétique). L'absence d'antibiogramme complet sur l'ensemble des 249 543 isolats limite la validation fonctionnelle directe.
• **Données manquantes taxonomiques :** Près de 45 % des isolats (112 068 entrées) ne possèdent pas de mention de sérovar validée, empêchant une stratification exhaustive par sérotype (ex. Typhimurium ST313 vs Enteritidis).

11. Conclusion & Perspectives d'Ingénierie Bioinformatique

Ce projet démontre l'efficacité d'un pipeline d'ingénierie bioinformatique combinant la puissance de traitement par flux d'UNIX et la précision analytique de Python. En validant rigoureusement l'ensemble des **20 critères techniques** du cahier des charges (orchestration par run.sh, getopts, gestion des signaux par trap, intégrité cryptographique SHA-256, permissions chmod 444, suite de tests pytest, et archivage automatique daté), notre solution fournit un outil clé en main, pérenne et totalement reproductible.
En perspective, ce pipeline pourra être étendu à la construction de réseaux de co-occurrence pangénomiques afin d'anticiper l'émergence de nouveaux super-plasmides de multi-résistance au sein des pathogènes prioritaires de l'OMS.